

Estimation par intervalle de confiance

2.1 Généralités

Soit X une variable aléatoire dont la loi dépend d'un paramètre inconnu θ (θ peut être une moyenne, une variance ou une proportion). Soit $(X_1, \dots, X_n)$ un n -échantillon de X et $(x_1, \dots, x_n)$ sa réalisation. Il s'agit d'estimer le paramètre θ .

L'estimation par intervalle de confiance consiste à trouver un intervalle $[a, b]$ qui a une grande probabilité $(1 - \alpha)$ de contenir le paramètre θ .

- $[a, b]$ = intervalle de confiance du paramètre inconnu θ .
- $1 - \alpha$ = niveau ou seuil de confiance (probabilité pour que θ appartienne à $[a, b]$).
- α = risque ou seuil d'erreur (probabilité pour que θ n'appartienne pas à $[a, b]$).
- $L = b - a$ est la **longueur de l'intervalle**.
- On appelle **marge d'erreur** associée à un intervalle de confiance la demi-longueur de cet intervalle.

Nous nous intéresserons dans ce chapitre à l'estimation des principales caractéristiques (ou paramètres) d'une variable aléatoire dans une population, à savoir **la moyenne**, **la variance** et **la fréquence**.

2.2 Intervalle de confiance de la moyenne d'une population normale

On considère un échantillon $(X_1, \dots, X_n)$ extrait d'une loi normale $\mathcal{N}(m, \sigma^2)$. On désigne par m le paramètre (la moyenne) inconnu. On admet que la moyenne empirique $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ et la variance empirique $S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ sont des variables aléatoires indépendantes. Pour déterminer l'intervalle de confiance de m , on distingue deux cas :

1^{er} cas : Ecart-type de la population (σ) connu

Proposition : Soit $X_1, \dots, X_n$ une suite de variable aléatoire indépendantes et identiquement distribuées suivant une loi normale $\mathcal{N}(m, \sigma^2)$. Alors la moyenne empirique $\bar{X}_n \sim \mathcal{N}(m, \frac{\sigma^2}{n})$, avec σ connu.

Ainsi, si σ est connu, alors $Z = \frac{\bar{X} - m}{\sigma/\sqrt{n}} = \frac{\sqrt{n}}{\sigma}(\bar{X} - m) \sim \mathcal{N}(0, 1)$.

Or si la variable aléatoire $Z \sim \mathcal{N}(0, 1)$, alors $\mathbb{P}(|Z| \leq t_\alpha) = 1 - \alpha$, avec t_α le quantile d'ordre $1 - \alpha/2$ de la loi normale centrée réduite $\mathcal{N}(0, 1)$. Donc, on a :

$$\Leftrightarrow \mathbb{P}\left(\left|\frac{\sqrt{n}}{\sigma}(\bar{X} - m)\right| \leq t_\alpha\right) = 1 - \alpha \Leftrightarrow \mathbb{P}\left(\bar{X} - t_\alpha \frac{\sigma}{\sqrt{n}} \leq m \leq \bar{X} + t_\alpha \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

D'où, si $\bar{x}$ est une réalisation de $\bar{X}$, l'intervalle de confiance de m au niveau $100(1 - \alpha)\%$ (ou de seuil α) a pour bornes :

$$a = \bar{x} - t_\alpha \frac{\sigma}{\sqrt{n}} \qquad b = \bar{x} + t_\alpha \frac{\sigma}{\sqrt{n}}$$

Exemple : Une machine remplit des capsules de poids moyen m et d'écart type 7.10 grammes. Sachant que le poids des capsules suit une loi normale de moyenne m , construire un intervalle de confiance de m au seuil de confiance 95% à l'aide d'un échantillon de taille 36 de moyenne $\bar{x} = 10$ grammes. Calculer la marge d'erreur associée. Combien de capsules doit remplir cette machine si le niveau de confiance exigé est de 90% avec une marge d'erreur n'excédant pas 5 gr pour le même écart-type ?

Solution :

2^{ième} cas : Ecart-type de la population (σ) inconnu

Proposition :

i) La variable aléatoire $S'^2 = \frac{n}{n-1} S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ est un estimateur sans biais et consistant de σ^2 .

ii) La variable aléatoire $T = \frac{\bar{X} - m}{S'/\sqrt{n}} \sim t_{n-1}$, la loi de Student à $n - 1$ degrés de libertés.

De cette proposition, on tire qu'au seuil $\alpha \in]0, 1[$ fixé on a

$$\mathbb{P}\left(\left|\frac{\sqrt{n}}{S'}(\bar{X} - m)\right| \leq t_\alpha\right) = 1 - \alpha \Leftrightarrow \mathbb{P}\left(\bar{X} - t_\alpha \frac{S'}{\sqrt{n}} \leq m \leq \bar{X} + t_\alpha \frac{S'}{\sqrt{n}}\right) = 1 - \alpha$$

où t_α désigne le quantile d'ordre $1 - \alpha/2$ de la loi de Student à $n - 1$ degrés de libertés. Au moyen d'un échantillon de taille n de moyenne $\bar{x}$ et d'écart type s' , on en déduit que les bornes de l'intervalle de confiance de m au niveau $1 - \alpha$ sont données par :

$$a = \bar{x} - t_\alpha \frac{s'}{\sqrt{n}} \quad b = \bar{x} + t_\alpha \frac{s'}{\sqrt{n}}$$

Exemple : Un analyste financier étudie les comptes de 200 clients ayant souscrit un emprunt. A partir d'un échantillon de 20 comptes il trouve que le solde moyen d'un compte est de 1514,69 euros avec un écart type de 453,34 euros. Donner un intervalle de confiance à 95% du solde moyen des compte si on suppose que le solde suit une loi normale de moyenne m et de variance σ^2 inconnu.

Solution :

Remarque : Si n est assez grand (en pratique dès que $n \geq 30$), on peut substituer les quantiles de la loi de Student à ceux de la loi normale centrée réduite pour établir l'intervalle de confiance au seuil α .

Exemple : On suppose que le pouls des chiens est une distribution normale et on prends le pouls de 40 chiens choisis au hasard et on trouve en moyenne 84 battements par minutes et un écart type de 11 battements par minute. Donner un intervalle de confiance de la moyenne à 95% puis à 99%.

2.3 Intervalle de confiance de la variance d'une population normale

Soit $(X_1, \dots, X_n)$ un échantillon de taille n extrait d'une loi normale de moyenne m et de variance σ^2 . Pour déterminer l'intervalle de confiance pour σ^2 , on distingue deux cas :

1^{er} cas : Moyenne de la population (m) connu

Proposition : si la moyenne m est connue, alors la variable aléatoire

$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2$ est un estimateur sans biais de σ^2 . De plus la variable aléatoire $U = n \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi_n^2$, la loi du Khi deux à n degrés de libertés.

En notant par $c_1 = \chi_n^2(1 - \alpha/2)$ et $c_2 = \chi_n^2(\alpha/2)$ respectivement les quantiles d'ordre $1 - \alpha/2$ et $\alpha/2$ de la loi de khi-deux à n degrés de libertés, on a :

$$\begin{aligned}\mathbb{P}(c_2 \leq U \leq c_1) &= 1 - \alpha \iff \mathbb{P}(c_2 \leq n \frac{\hat{\sigma}^2}{\sigma^2} \leq c_1) = 1 - \alpha \\ &\iff \mathbb{P}\left(\frac{n\hat{\sigma}^2}{c_1} \leq \sigma^2 \leq \frac{n\hat{\sigma}^2}{c_2}\right) = 1 - \alpha\end{aligned}$$

Ainsi, l'intervalle de confiance de σ^2 au seuil α est de la forme suivante

$$\sigma^2 \in \left[\frac{n\hat{\sigma}^2}{c_1}, \frac{n\hat{\sigma}^2}{c_2} \right]$$

2^{ème} cas : Moyenne de la population (m) inconnu

Si m est inconnue, la variable aléatoire $U = \frac{(n-1)S'^2}{\sigma^2} \sim \chi_{n-1}^2$, la loi du Khi deux à $n - 1$ degrés de libertés. Ainsi en notant par $c_1 = \chi_n^2(1 - \alpha/2)$ et $c_2 = \chi_n^2(\alpha/2)$ respectivement les quantiles d'ordre $1 - \alpha/2$ et $\alpha/2$ de la loi de khi-deux à $n - 1$ degrés de libertés, l'intervalle de confiance de σ^2 au seuil α est de la forme suivante

$$\sigma^2 \in \left[\frac{(n-1)s'^2}{c_1}, \frac{(n-1)s'^2}{c_2} \right]$$

où $s'^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ est l'estimateur non biaisée de σ^2 .

Exemple : Dans une supérette on suppose que le nombre de visiteurs par heure suit une loi normale. On veut connaître le nombre de visiteurs moyen par heure. Pour cela on dispose d'un échantillon du nombre de visiteurs par heure pendant 12 heures :

30 25 35 18 22 28 36 38 44 41 30 37 .

- Estimer par intervalle de confiance de seuil $\alpha = 5\%$ la variance du nombre de visiteurs par heure de cette supérette.
- Répondre à la même question en supposant que la moyenne du nombre de visiteur par heure est de 30.

2.4 Intervalle de confiance d'une proportion

Soit une population P ayant une proportion p d'individus ayant un caractère C, p inconnu. On considère un échantillon de taille n (n assez grand) de cette population. Si dans

l'échantillon k individus possèdent le caractère C, l'estimation ponctuelle de p est : $f = \frac{k}{n}$.
L'intervalle de confiance de p au seuil de confiance $1 - \alpha$ est

$$IC_{\alpha}(p) = \left[f - t_{\alpha} \sqrt{\frac{f(1-f)}{n}}; f + t_{\alpha} \sqrt{\frac{f(1-f)}{n}} \right]$$

t_{α} est le quantile d'ordre $1 - \alpha/2$ de la loi normale centrée réduite $\mathcal{N}(0, 1)$.

Exemple : On veut connaître le taux de satisfaction d'un nouveau produit A. Pour cela on interroge un échantillon de 100 consommateurs et 60 parmi eux disent être satisfaits du produit A. Estimer par intervalle de confiance le taux réel de satisfaction au seuil de confiance de 95%.

2.5 Intervalle de confiance de la différence de deux moyennes de populations normales

On considère deux populations normales $\mathcal{N}(m_1, \sigma_1^2)$ et $\mathcal{N}(m_2, \sigma_2^2)$ de moyennes respectives m_1 et m_2 inconnues. On cherche un intervalle de confiance de niveau $100(1 - \alpha)\%$ de la différence $m_1 - m_2$. A cette fin, on prélève un échantillon de taille n_1 (resp n_2) de la population 1 (resp population 2). On distingue deux cas :

1^{er} cas : σ_1 et σ_2 connus

En notant $\bar{X}_1$ et $\bar{X}_2$ les moyennes empiriques échantillonnales, si n_1 et n_2 sont assez grand, alors la variable aléatoire

$$Z = \frac{\bar{X}_1 - \bar{X}_2 - (m_1 - m_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0, 1).$$

Donc en utilisant le même procédé que précédemment, on montre que les bornes de l'intervalle de confiance de la différence $m_1 - m_2$ au seuil α sont données par :

$$a = \bar{x}_1 - \bar{x}_2 - t_{\alpha} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \quad \text{et} \quad b = \bar{x}_1 - \bar{x}_2 + t_{\alpha} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

où t_{α} représente le quantile d'ordre $1 - \alpha/2$ de la loi normale centrée réduite $\mathcal{N}(0, 1)$.

2.6. Intervalle de confiance du rapport des variances de deux lois normales

Exemple : On soumet à un essai des poutres en aluminium de deux qualités différentes devant faire partie de la voilure d'un avion en ligne. On prélève deux échantillons sur leur résistance à la traction et on suppose que l'on connaît l'écart type de cette résistance dans chaque cas. Construire un intervalle de confiance de seuil 10% de la différence $m_1 - m_2$. On donne

Echantillon 1 : $n_1 = 10$ $\bar{x}_1 = 87.6$ $\sigma_1 = 1$
Echantillon 2 : $n_2 = 12$ $\bar{x}_2 = 74.5$ $\sigma_2 = 1.5$

2^{ème} cas : σ_1 et σ_2 inconnus avec $\sigma_1 = \sigma_2 = \sigma$

Puisque les variances empiriques $S_1'^2$ et $S_2'^2$ des deux échantillons fournissent une estimation de la variance commune σ^2 , on peut définir un estimateur de σ^2 combinaison de $S_1'^2$ et $S_2'^2$ noté

$$S_p^2 = \frac{(n_1 - 1)S_1'^2 + (n_2 - 1)S_2'^2}{n_1 + n_2 - 2}$$

En admettant le fait la variable aléatoire T définie par

$$T = \frac{\bar{X}_1 - \bar{X}_2 - (m_1 - m_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1 + n_2 - 2}$$

une loi de Student à $n_1 + n_2 - 2$ degrés de libertés, on en déduit donc qu'au seuil α , on a

$$a = \bar{x}_1 - \bar{x}_2 - t_\alpha s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \quad b = \bar{x}_1 - \bar{x}_2 + t_\alpha s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

où t_α est le quantile d'ordre $1 - \alpha/2$ de la loi de Student à $n_1 + n_2 - 2$ degrés de libertés.

Exemple : Soient deux populations normales indépendantes de variances inconnues dont on tire un échantillon de taille $n_1 = 15$ et de taille $n_2 = 10$. La moyenne et la variance du premier échantillon sont respectivement $\bar{x}_1 = 300$ et $s_1^2 = 16$ et celles du second échantillon sont $\bar{x}_2 = 325$ et $s_2^2 = 49$.

En supposant que les variances des populations égales, définissez pour $\mu_1 - \mu_2$ un intervalle de confiance à 95%.

2.6 Intervalle de confiance du rapport des variances de deux lois normales

On considère deux populations normales $\mathcal{N}(m_1, \sigma_1^2)$ et $\mathcal{N}(m_2, \sigma_2^2)$ de moyennes et de variances inconnues. On souhaite construire un intervalle de confiance au niveau

100(1 - α)% du rapport $\frac{\sigma_1^2}{\sigma_2^2}$. Pour cela on considère un échantillon de taille n_1 et de moyenne $\bar{X}_1$ extrait de la population 1 et un échantillon de taille n_2 et de moyenne $\bar{X}_2$ extrait de la population 2. En considérant $S_1'^2$ (resp $S_2'^2$) l'estimateur non biaisé de σ_1^2 (resp σ_2^2), on note que la variable aléatoire

$$F = \frac{S_2'^2/\sigma_2^2}{S_1'^2/\sigma_1^2} \sim F_{n_2-1, n_1-1}$$

la loi de Fisher à $n_2 - 1$, $n_1 - 1$ degrés de libertés. On en déduit alors que

$$\begin{aligned} & \mathbb{P}(F_{n_2-1, n_1-1}(\alpha/2) \leq F \leq F_{n_2-1, n_1-1}(1 - \alpha/2)) = 1 - \alpha \\ \iff & \mathbb{P}\left(\frac{S_1'^2}{S_2'^2} F_{n_2-1, n_1-1}(\alpha/2) \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1'^2}{S_2'^2} F_{n_2-1, n_1-1}(1 - \alpha/2)\right) = 1 - \alpha \end{aligned}$$

Donc l'intervalle de confiance au niveau $1 - \alpha$ est donné par

$$\frac{s_1'^2}{s_2'^2} F_{n_2-1, n_1-1}(\alpha/2) \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{s_1'^2}{s_2'^2} F_{n_2-1, n_1-1}(1 - \alpha/2)$$

où $F_{n_2-1, n_1-1}(\alpha/2)$ et $F_{n_2-1, n_1-1}(1 - \alpha/2)$ sont respectivement les quantiles d'ordre $\alpha/2$ et $1 - \alpha/2$ de la loi de Fisher à $n_2 - 1$, $n_1 - 1$ degrés de libertés.

Exemple : Lors d'une étude visant à comparer deux catalyseurs par leur capacité à réduire la durée d'immersion nécessaire à la gravure de circuits imprimés, on a procédé à $n_1 = 12$ essais avec le catalyseur 1 et à $n_2 = 15$ essais avec le catalyseur 2, d'où il ressort que $s_1' = 0.85$ mn et que $s_2' = 0.98$ mn. Quel est l'intervalle de confiance de niveau 95% du rapport $\frac{\sigma_1^2}{\sigma_2^2}$.

2.7 Intervalle de confiance de la différence de deux proportions

Soit une population $\mathcal{P}_1$ (resp $\mathcal{P}_2$) ayant une proportion p_1 (resp p_2) inconnue d'individus ayant un caractère C. On suppose que les deux populations sont indépendantes.

On considère un échantillon de taille n_1 (resp. n_2) de la population $\mathcal{P}_1$ (resp $\mathcal{P}_2$). On note par k_1 (resp. k_2) le nombre d'individus dans l'échantillon de taille n_1 (resp. n_2) présentant le caractère C.

Les estimations ponctuelles de p_1 et p_2 sont respectivement $f_1 = \frac{k_1}{n_1}$ et $f_2 = \frac{k_2}{n_2}$.

L'intervalle de confiance de la différence $p_1 - p_2$ au niveau de confiance $1 - \alpha$ a pour bornes :

$$a = f_1 - f_1 - t_\alpha D \qquad a = f_1 - f_1 + t_\alpha D$$

avec

$$D = \sqrt{\frac{f_1(1 - f_1)}{n_1} + \frac{f_2(1 - f_2)}{n_2}}$$

t_α est le quantile d'ordre $1 - \alpha/2$ de la loi normale centrée réduite $\mathcal{N}(0, 1)$.

Exemple : Dans deux succursales d'une Entreprise, on souhaite étudier la différence des proportions de pièces défectueuses. Dans la succursale S_1 , douze des 75 arbres prélevés présentent un défaut de fabrication. Dans S_2 dix des 85 arbres prélevés présentent un défaut de fabrication. Donner une estimation par intervalle à 90% de la différence des deux proportions considérées.