

Tests de comparaison

4.1 Généralités sur les tests de comparaison

On considère deux variables aléatoires X_1 et X_2 définies sur deux populations P_1 et P_2 respectivement. Ces variables aléatoires dépendent d'un paramètre inconnu θ_1 et θ_2 respectivement. On veut tester l'hypothèse $(H_0) : \theta_1 - \theta_2 = 0$ contre $(H_1) : \theta - \theta_2 \neq 0$, ou $\theta_1 > \theta_2$ ou $\theta_1 < \theta_2$.

4.2 Tests de comparaison de deux proportions

Soit p_1 la proportion inconnue d'individus possédant un certain caractère A dans la population 1 et p_2 la proportion inconnue d'individus possédant ce même caractère dans la population 2.

On dispose d'un n_1 -échantillon de la population 1 et un n_2 -échantillon de la population 2. Soient f_1 la fréquence empirique associée à l'échantillon 1 et f_2 la fréquence empirique associée à l'échantillon 2. On calcule les fréquences f_1 et f_2 des échantillons 1 et 2 en posant $f_1 = \frac{k_1}{n_1}$ et $f_2 = \frac{k_2}{n_2}$, où k_1 est le nombre d'individus possédant le caractère A dans l'échantillon 1 et k_2 est le nombre d'individus possédant le caractère A dans l'échantillon 2. On cherche à tester l'hypothèse (H_0) . Pour cela, on calcule la valeur de la statistique du test t_0 définie par :

$$t_0 = \frac{f_1 - f_2}{\sqrt{\hat{p}(1 - \hat{p}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

avec $\hat{p}$ l'estimation de la proportion commune : $\hat{p} = \frac{k_1 + k_2}{n_1 + n_2}$.

- **Test 1 : Test bilatéral**

– On veut tester au seuil α : $\begin{cases} H_0 : p_1 = p_2 \\ H_1 : p_1 \neq p_2 \end{cases}$

- La région critique C est : $|t_0| > t_\alpha$, où t_α est le quantile d'ordre $1 - \alpha/2$ de la loi normale centrée réduite $\mathcal{N}(0, 1)$.
- **Conclusion** : si t_0 appartient à C , on rejette H_0 . On accepte H_0 si t_0 appartient à $[-t_\alpha; t_\alpha]$.

Exemple : Deux machine A et B fabriquent en série la même pièce. La machine A fournit 2700 pièces avec 60 défectueuses. La machine B fournit 1000 pièces avec 50 défectueuses. Doit-on conclure qu'une machine est mieux réglée que l'autre, au risque d'erreur de 10% ?

• **Test 2 : Test unilatéral à droite**

- On veut tester au seuil α :
$$\begin{cases} H_0 : p_1 \leq p_2 \\ H_1 : p_1 > p_2 \end{cases}$$
- La région critique C est : $t_0 \geq t_\alpha$ avec t_α est le quantile d'ordre $1 - \alpha$ de la loi normale centrée réduite $\mathcal{N}(0, 1)$.
- **Conclusion** : si t_0 appartient à C , on rejette H_0 . On accepte H_0 si $t_0 < t_\alpha$.

• **Test 3 : Test unilatéral à gauche**

- On veut tester au seuil α :
$$\begin{cases} H_0 : p_1 \geq p_2 \\ H_1 : p_1 < p_2 \end{cases}$$
- La région critique C est : $t_0 \leq -t_\alpha$ avec t_α est le quantile d'ordre $1 - \alpha$ de la loi normale centrée réduite $\mathcal{N}(0, 1)$.
- **Conclusion** : si t_0 appartient à C , on rejette H_0 . On accepte H_0 si $t_0 > -t_\alpha$.

Exemple : Un échantillon de sondage électoral constitué de deux groupes d'électeurs de circonscription A et B , de tailles 200 et 300 respectivement, a mis en évidence des intentions de votes de 56% et 48% pour un candidat donné. Le candidat est-il préféré dans la circonscription A au risque de 5% ?

4.3 Tests de comparaison de deux moyennes

Soient deux populations P_1 et P_2 et deux variable X_1 et X_2 définies respectivement sur P_1 et P_2 , X_1 et X_2 étant indépendantes. On suppose que X_1 est distribuée suivant une loi normale $\mathcal{N}(m_1, \sigma_1^2)$ et X_2 suivant une loi normale $\mathcal{N}(m_2, \sigma_2^2)$.

On dispose d'un n_1 -échantillon de X_1 qui donne une moyenne $\bar{x}_1$ et un écart-type s_1 et d'un n_2 -échantillon de X_2 qui donne une moyenne $\bar{x}_2$ et un écart type s_2 .

On veut tester l'hypothèse $(H_0) : m_1 = m_2$ contre l'hypothèse $(H_1) : m_1 \neq m_2$ ou $m_1 > m_2$

ou $m_1 < m_2$.

Pour cela, on distingue deux cas :

1^{er} cas : σ_1 et σ_2 connus

On calcule d'abord la valeur de la statistique du test donnée par

$$t_0 = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

• Test 1 : Test bilatéral

- On veut tester au seuil α : $\begin{cases} H_0 : m_1 = m_2 \\ H_1 : m_1 \neq m_2 \end{cases}$
- La région critique C est : $|t_0| > t_\alpha$, où t_α est le quantile d'ordre $1 - \alpha/2$ de la loi normale centrée réduite $\mathcal{N}(0, 1)$.
- **Conclusion** : si t_0 appartient à C, on rejette H_0 . On accepte H_0 si t_0 appartient à $[-t_\alpha; t_\alpha]$.

Exemple : Deux machines remplissent des boîtes de thé dont l'écart type du poids est 0,045 kg. Pour la première machine, sur un échantillon de 100 boîtes, on trouve un poids moyen de 6,11 kg et pour la deuxième, sur un échantillon de 200 boîtes on trouve un poids moyen de 6,14 kg. Le poids moyen des boîtes pour la première machine diffère-t-il significativement du poids moyen pour la deuxième machine au seuil $\alpha = 5\%$.

• Test 2 : Test unilatéral à droite

- On veut tester au seuil α : $\begin{cases} H_0 : m_1 \leq m_2 \\ H_1 : m_1 > m_2 \end{cases}$
- La région critique C est : $t_0 \geq t_\alpha$ avec t_α est le quantile d'ordre $1 - \alpha$ de la loi normale centrée réduite $\mathcal{N}(0, 1)$.
- **Conclusion** : si t_0 appartient à C, on rejette H_0 . On accepte H_0 si $t_0 < t_\alpha$.

• Test 3 : Test unilatéral à gauche

- On veut tester au seuil α : $\begin{cases} H_0 : m_1 \geq m_2 \\ H_1 : m_1 < m_2 \end{cases}$
- La région critique est C : $t_0 \leq -t_\alpha$ avec t_α est le quantile d'ordre $1 - \alpha$ de la loi normale centrée réduite $\mathcal{N}(0, 1)$.
- **Conclusion** : si t_0 appartient à C, on rejette H_0 . On accepte H_0 si $t_0 > -t_\alpha$.

Exemple :

2^{ème} cas : σ_1 et σ_2 inconnus, avec $\sigma_1 = \sigma_2 = \sigma$

On estime d'abord l'écart type commun σ par :

$$S_p = \sqrt{\frac{n_1 s_1^2 + n_2 s_2^2}{n_1 + n_2 - 2}}$$

où s_1^2 et s_2^2 désignent respectivement les variances des n_1 -échantillon et n_2 -échantillon. On prends ensuite comme variable de décision

$$t_0 = \frac{\bar{x}_1 - \bar{x}_2}{s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

• **Test 1 : Test bilatéral**

- On veut tester au seuil α : $\begin{cases} H_0 : m_1 = m_2 \\ H_1 : m_1 \neq m_2 \end{cases}$
- La région critique C est : $|t_0| > t_\alpha$,
 - si $n_1 + n_2 - 2 < 30$, t_α est le quantile d'ordre $1 - \alpha/2$ de la loi de student à $n_1 + n_2 - 1$ degrés de libertés.
 - si $n_1 + n_2 - 2 \geq 30$, t_α est le quantile d'ordre $1 - \alpha/2$ de la loi normale centrée réduite $\mathcal{N}(0, 1)$.
- **Conclusion** : si t_0 appartient à C, on rejette H_0 . On accepte H_0 si t_0 appartient à $[-t_\alpha; t_\alpha]$.

Exemple : Une entreprise d'éclairage public désire choisir entre deux marques A et B de tubes fluorescents. Sur deux échantillons de marque A et B on observe les résultats suivants : moyenne de vie des tubes et écart-type en heures.

Marque	Taille	Moyenne de vie	Ecart-type
A	50	33300 h	1200 h
B	80	33100 h	1300 h

La différence des moyennes est-elle significative au seuil de 5%

• **Test 2 : Test unilatéral à droite**

- On veut tester au seuil α : $\begin{cases} H_0 : m_1 \leq m_2 \\ H_1 : m_1 > m_2 \end{cases}$

- La région critique C est : $t_0 \geq t_\alpha$
 - si $n_1 + n_2 - 2 < 30$, t_α est le quantile d'ordre $1 - \alpha$ de la loi de student à $n_1 + n_2 - 1$ degrés de libertés.
 - si $n_1 + n_2 - 2 \geq 30$, t_α est le quantile d'ordre $1 - \alpha$ de la loi normale centrée réduite $\mathcal{N}(0, 1)$.
- **Conclusion** : si t_0 appartient à C, on rejette H_0 . On accepte H_0 si $t_0 < t_\alpha$.
- **Test 3 : Test unilatéral à gauche**
 - On veut tester au seuil α :
$$\begin{cases} H_0 : m_1 \geq m_2 \\ H_1 : m_1 < m_2 \end{cases}$$
 - La région critique est C : $t_0 \leq -t_\alpha$
 - si $n_1 + n_2 - 2 < 30$, t_α est le quantile d'ordre $1 - \alpha$ de la loi de student à $n_1 + n_2 - 1$ degrés de libertés.
 - si $n_1 + n_2 - 2 \geq 30$, t_α est le quantile d'ordre $1 - \alpha$ de la loi normale centrée réduite $\mathcal{N}(0, 1)$.
 - **Conclusion** : si t_0 appartient à C, on rejette H_0 . On accepte H_0 si $t_0 > -t_\alpha$.

Exemple : Un agriculteur teste l'efficacité d'un fertilisant sur le rendement de sa production. Pour cela il exploite 24 plants d'égales surfaces dont la moitié est traitée et l'autre moitié est gardée sous contrôle (c'est-à-dire non traitée). Le rendement moyen des surfaces non traitées est de 4.8 tonnes avec un écart type de 0.4 tonnes, tandis celui des surfaces traitées est de 5.1 tonnes et un écart type de 0.36 tonnes. On suppose que les rendements sont normalement distribués et de variances égales. Quelle conclusion peut il en tirer au seuil $\alpha = 0.05$?

4.4 Tests d'égalité de deux variances

Soient deux populations P_1 et P_2 et deux variable X_1 et X_2 définies respectivement sur P_1 et P_2 , X_1 et X_2 étant indépendantes. On suppose que X_1 est distribuée suivant une loi normale $\mathcal{N}(m_1, \sigma_1^2)$ et X_2 suivant une loi normale $\mathcal{N}(m_2, \sigma_2^2)$.

On dispose d'un n_1 -échantillon de X_1 qui donne une variance s_1^2 et d'un n_2 -échantillon de X_2 qui donne une variance s_2^2 .

- On veut tester
$$\begin{cases} H_0 : \sigma_1^2 = \sigma_2^2 \\ H_1 : \sigma_1^2 \neq \sigma_2^2 \end{cases}$$

- On prend comme variable de décision, la statistique

$$t_0 = \frac{\frac{n_1 s_1^2}{n_1 - 1}}{\frac{n_2 s_2^2}{n_2 - 1}}$$

- **La région critique C** est : t_0 n'appartient pas à l'intervalle $[F(\alpha/2), F(1 - \alpha/2)]$, avec $F(1 - \alpha/2)$ et $F(\alpha/2)$ représentent respectivement les quantiles d'ordre $1 - \alpha/2$ et $\alpha/2$ de la loi de Fisher à $n_1 - 1$ et $n_2 - 1$ degrés de libertés.
- **Conclusion** : si t_0 appartient à C, on rejette (H_0) . On accepte (H_0) si $t_0 \in [F(\alpha/2), F(1 - \alpha/2)]$.

Exemple : Un professeur enseigne à deux classes, A et B , de 15 élèves et de 13 élèves respectivement. Au cours d'un examen l'écart-type de la classe A est 9, alors que celui de la classe B est 12. Peut-on conclure qu'au niveau de signification de 0,05, que les dispersions des deux classes sont identiques ?