

Tests du Khi-deux

5.1 Introduction

Dans les chapitres précédents, on a présenté uniquement des méthodes d'inférence paramétriques, c'est à dire des méthodes permettant de tirer des conclusions sur les paramètres d'une population à partir d'informations partielles. Or en pratique, on peut vouloir tirer des conclusions non pas sur les paramètres de la population mais sur la distribution d'une variable X , ou encore sur les relations de X avec d'autres variables. Dans cette situation, on fait appel à une méthode d'inférence non paramétrique qui ne suppose pas la normalité de la population.

Dans ce qui suit, nous allons nous limiter aux tests non paramétriques, et parmi ces tests, nous présenterons seulement : le test d'indépendance de Khi-deux et le test d'homogénéité.

5.2 Tests d'indépendance de deux caractères

Dans la plupart des tests que nous venons de présenter, on suppose toujours les valeurs de l'échantillon indépendantes. C'est une condition nécessaire. Il est donc souvent utile de vérifier cette hypothèse par un test. Ce test met en place une variable aléatoire qui suit une loi du khi-deux, aussi ce test est appelé **Test d'indépendance du khi-deux**.

Ce test permet de contrôler l'indépendance de deux caractères dans une population donnée. On dispose de deux variables aléatoires X et Y , les valeurs possibles de X sont réparties en l modalités (ou classes) $X_1, \dots, X_l$, celles de Y en k modalités $Y_1, \dots, Y_k$. Pour chaque intersection de modalités X_i et Y_j , un effectif $n_{i,j}$ est observé. Ainsi

$$n = \sum_{i=1}^l \sum_{j=1}^k n_{i,j}$$

Hypothèse testée H_0 : "Les variables X et Y sont indépendantes".

Déroulement du test : On crée le tableau des effectifs qui est un tableau à double-entrée. A l'intersection de la i -ème ligne et de la j -ième colonne, on écrit l'effectif $n_{i,j}$.

On calcule les effectifs marginaux : $n_{i,\bullet} = \sum_{j=1}^k n_{i,j}$ est la somme des termes sur la i -ème ligne et $n_{\bullet,j} = \sum_{i=1}^l n_{i,j}$ est la somme des termes sur la j -ième colonne.

- On calcule les effectifs théoriques :

$$C_{i,j} = \frac{n_{i,\bullet} \times n_{\bullet,j}}{n}$$

- On calcule la valeur de la variable de test :

$$\chi_{\text{obs}}^2 = \sum_{i=1}^l \sum_{j=1}^k \frac{(n_{i,j} - C_{i,j})^2}{C_{i,j}} = n \left[\sum_{i=1}^l \sum_{j=1}^k \frac{n_{i,j}^2}{n_{i,\bullet} \times n_{\bullet,j}} - 1 \right]$$

- On cherche la valeur critique $\chi_{1-\alpha}^2$ dans la table de la loi du χ^2 à $\nu = (l-1) \times (k-1)$ degrés de liberté.

- **Décision** : si $\chi_{\text{obs}}^2 < \chi_{1-\alpha}^2$, on accepte l'hypothèse (H_0), sinon on la rejette.

Remarque : Vérification a posteriori des conditions d'application : il faut $C_{i,j} \geq 5$ pour tous i, j .

Exemple 1 : Pour comparer l'efficacité de deux médicaments agissant sur la même maladie, mais aux prix très différents, la Sécurité Sociale a effectué une enquête sur les guérisons obtenues en suivant chacun des traitements. Les résultats sont consignés dans le tableau suivant :

	Médicament	Générique	total
Guérisons	48	158	206
non Guérisons	6	44	50
total	54	202	256

On calcule : $\chi_{\text{obs}}^2 = \frac{48^2}{54 \times 206} + \frac{158^2}{202 \times 206} + \frac{6^2}{54 \times 50} + \frac{44^2}{202 \times 50} \approx 3.1$

La variable de test χ_{obs}^2 vaut approximativement 3.1, alors que la valeur critique, pour un niveau de risque de 5%, est 3.84 (on explore la table du χ^2 à un degré de liberté). On peut donc raisonnablement estimer ici que le taux de guérison ne dépend pas du prix du médicament et se poser des questions sur l'opportunité de continuer à vendre le médicament cher.

5.3 Tests d'homogénéité

Dans une population formée d'individus répartis en différentes catégories (hommes/femmes, classes d'âges, niveaux socio-économiques, etc...), on observe une variable (effet d'un médicament, présence d'un comportement à risque, performances ...) et on se demande si ses variations selon les différentes catégories de la population sont simplement dues aux fluctuations d'échantillonnage ou si au contraire elles révèlent des comportements différents de la variable dans chacune de ces catégories. Nous allons conclure grâce à un test d'homogénéité dont nous expliquons tout d'abord le principe sur un exemple.

Exemple 2 : Dans une université où les initiatives pédagogiques différenciées sont vivement encouragées trois groupes de professeurs ont mis au point trois méthodes différentes d'apprentissage des Mathématiques qu'on a appliqué à trois échantillons d'étudiants ayant sensiblement le même niveau initial. À l'examen les résultats furent les suivants :

Observés	Admis	Ajournés	Total
Méthode 1	51	29	80
Méthode 2	38	12	50
Méthode 3	86	34	120
Total	175	75	250

Peut-on affirmer que l'une des trois méthodes est plus efficace que les autres en termes de réussite à l'examen ?

Pour répondre à cette question, on teste l'hypothèse H_0 : *il n'y a pas de différence significative entre les pourcentages de réussite de ces trois groupes d'étudiants*, contre l'hypothèse H_1 : *une au moins de ces méthodes est significativement plus efficace que les autres*.

Pour effectuer ce test on compare le **tableau des effectifs observés** ci-dessus au **tableau des effectifs théoriques** ci-dessous correspondant à une population, regroupant les trois groupes, qui serait parfaitement homogène si H_0 était vrai. Le nombre théorique d'admis parmi les étudiants ayant suivi la méthode 1 sera égal à $56 = \frac{175}{250}80$ car il y a un taux de réussite global de $175/250 = 70\%$ et le nombre total d'étudiants ayant suivi la méthode 1 est de 80.

Théoriques	Admis	Ajournés	Total
Méthode 1	56	24	80
Méthode 2	35	15	50
Méthode 3	84	36	120
Total	175	75	250

On calcule alors le Khi Deux de ces tableaux 3×2 d'effectifs, noté χ_{obs}^2 de la façon suivante :

$$\chi_{\text{obs}}^2 = \sum_{i=1}^l \sum_{j=1}^k \frac{(n_{i,j} - C_{i,j})^2}{C_{i,j}} = \frac{(51 - 56)^2}{56} + \dots + \frac{(34 - 36)^2}{36} \approx 2.51$$

Sous des hypothèses généralement satisfaites dans la pratique (échantillons disjoints, sélectionnés de façon indépendante et de taille suffisante), on peut considérer que la quantité χ_{obs}^2 qui est aléatoire (car elle dépend du choix des échantillons) suit une loi du khi deux ayant un nombre de degré de liberté dl égal à $dl = (k - 1) \times (l - 1)$.

Pour tout choix d'un seuil α , on note $\chi_{dl}^2(1 - \alpha)$ le quantile d'ordre $1 - \alpha$ de la loi de khi deux à dl degrés de liberté. On conclut, au risque α (c'est-à-dire avec une probabilité de rejet à tort de α), que :

- Si $\chi_{\text{obs}}^2 \geq \chi_{dl}^2(1 - \alpha)$, l'hypothèse H_0 doit être rejetée, c'est-à-dire que les trois méthodes d'apprentissage ne peuvent être considérées comme équivalentes.
- Si $\chi_{\text{obs}}^2 < \chi_{dl}^2(1 - \alpha)$, on ne peut pas rejeter l'hypothèse H_0 , c'est-à-dire que, malgré les différences de résultats à l'examen, les méthodes se valent.

Ainsi, si on se fixe comme seuil $\alpha = 5\%$, la valeur de $\chi_{dl}^2(1 - \alpha)$ sur la table de loi de khi deux donne : 5.991 qui est supérieure à $\chi_{\text{obs}}^2 = 2.51$, donc on accepte l'hypothèse H_0 .

Conclusion Avec un risque de 5%, les trois méthodes d'apprentissage se valent.